HW1

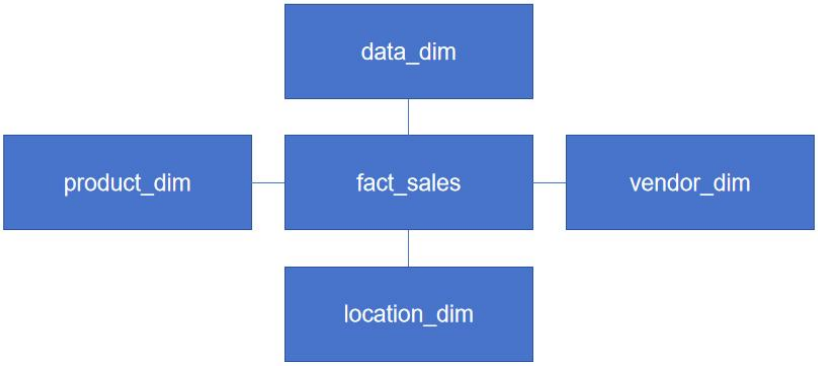
Due Date: Oct. 12, 2026

Submission requirements:

Please submit your solutions to our class website. Only hand in what is required below.

1. 假定数据仓库中包含 4 个维：date, product, vendor, location；和两个度量：sales_volume 和 sales_cost。
(a) 画出该数据仓库的星形模式图。

答：星型模式图如下：



其中，中间的事实表为：

```
fact_sales(
  date_key,
  product_key,
  vendor_key,
  location_key,
  sales_volume,
  sales_cost
)
```

(b) 由基本方体[date, product, vendor, location]开始，列出每年在 Los Angles 的每个 vendor 的 sales_volume。

答：由基本方体[date, product, vendor, location]开始：
选择 location = ‘Los Angles’；
将 date 上卷到 year；
然后将 product 上卷到 all；
按 vendor 来分组；
最后对 sales_volume 求和。
得到结果表:

year	vendor	sales_volume
年份	供应商	该年 Los Angeles 该 vendor 的销售总量

(c) 对于数据仓库，位图索引是有用的。以该立方体为例，简略讨论使用位图索引结构的优点和问题。

答：
优点：
1. 等值查询快：位运算直接定位满足条件的行。
2. 适合 AND/OR/NOT 组合查询：多个条件可以快速做位与、位或、位非。
3. 压缩效率高：低基数列的位图通常很稀疏或规律性强，容易压缩。
4. 适合 OLAP：多维分析中经常按维筛选、分组、计数。
5. 计数方便：统计满足条件的行数很快。

问题：
1. 高基数列不合适：如具体日期、具体产品 ID、精确交易号，位图会非常大且稀疏。
2. 更新代价高：插入、删除、更新一行时，可能影响很多位图。
3. 空间问题：如果基数太高，位图索引可能比普通索引更占空间。
4. 并发更新锁问题：数据仓库通常批量加载、只读查询多，位图合适；但频繁更新的事务系统不合适。
5. 维护复杂：需要为不同取值维护位向量，编码和压缩策略会影响性能。

2. Design a data warehouse for a regional weather bureau. The weather bureau has about 1000 probes, which are scattered throughout various land and ocean locations in the region to collect basic weather data, including air pressure, temperature, and precipitation at each hour. All data are sent to the central station, which has collected such data for over 10 years. Your design should facilitate efficient querying and online analytical processing, and derive general weather patterns in multidimensional space. (note: please present the schema, the fact table(s) and the dimension tables with concept hierarchy)

答：
模式使用：星型模式



事实表的结构为：
Weather_Fact(
 time_id,
 probe_id,
 location_id,
 air_pressure,
 temperature,
 precipitation
)
其中，外键为：time_id、probe_id、location_id；
度量为：
air_pressure：气压
temperature：温度
precipitation：降水量

维度表的结构及其概念层次为：
Time_Dim(
 time_id,

hour,
day,
month,
quarter,
year,
season,
weekday
)
该表的概念层次为： hour → day → month → quarter → year；day → season → year
Probe_Dim(
probe_id,
probe_name,
probe_type,
manufacturer,
install_date,
status,
station_id,
station_name,
network
)
该表的概念层次为：probe → station → network；probe → probe_type → manufacturer
Location_Dim(
location_id,
latitude,
longitude,
altitude_or_depth,
land_ocean,
city_or_region,
region,
climate_zone,
country
)
该表的概念层次为：Location_Dim: location → city_or_region → region → climate_zone → country；location → land_ocean → region → climate_zone

3. 下面是一个超市商品 A 连续 20 个月的销售数据（单位为百元）
21,16,19,24,27,23,22,21,20,17,16,20,23,22,18,24,26, 25,20,26。

(a) Calculate the mean, median, and standard deviation of the sales

data.

答：
平均值：21.5
中位数：21.5
总体标准差：3.22
样本标准差：3.30

(b) Draw the boxplot.

(c) Normalize the values based on *min-max normalization*.

答：min=16
max=27
max−min=11
所以归一化的序列为：
0.4545,0,0.2727,0.7273,1,0.6364,0.5455,0.4545,0.3636,0.0909,0,0.3636,0.6364,0.5455,0.1818,0.7273,0.9091,0.8182,0.3636,0.9091

(d) 假设商品 B 连续 20 个月的销售数据（单位为百元）如下：38, 24, 38, 45, 46, 44, 42, 34, 40, 30, 31, 40, 40, 32, 36, 42, 50, 47, 46, 50。Calculate the *correlation coefficient* (Pearson's product moment coefficient). Are these products positively or negatively correlated?

答：
r=0.831>0，所以商品 A 和商品 B 的销售量是正相关的。也就是说，A 销量高较高时，B 的销量通常也较高。

(e) Draw the scatter plot for the sales data of the two products.

4. 下面是一个超市商品 A 连续 20 个月的销售数据（单位为百元）。21,16,19,24,27,23,22,21,20,17,16,20,23,22,18,24,26, 25,20,26。对以上数据进行噪声平滑，使用深度为 5 的 Equal-depth binning 方法。

(a) 采用 bin median 方法进行平滑；

答：
深度为 5，所以分为 4 个箱：
箱 1: 16,16,17,18,19，中位数为：17
箱 2: 20,20,20,21,21，中位数为：20
箱 3: 22,22,23,23,24，中位数为：23
箱 4: 24,25,26,26,27，中位数为：26
则平滑结果为：
17,17,17,17,17,
20,20,20,20,20,
23,23,23,23,23,
26,26,26,26,26

(b) 采用 bin boundaries 方法进行平滑。

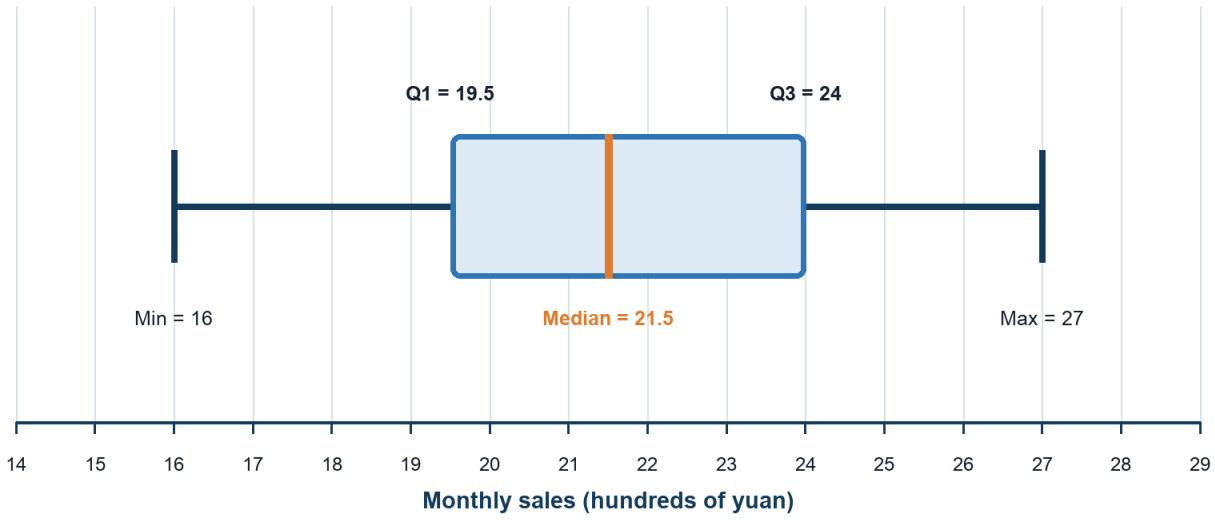
答：
深度为 5，所以分为 4 个箱：
箱 1: 16,16,17,18,19，边界为[16,19]
箱 2: 20,20,20,21,21，边界为[20,21]
箱 3: 22,22,23,23,24，边界为[22,24]
箱 4: 24,25,26,26,27，边界为[24,27]
则平滑结果为：
16,16,16,19,19,
20,20,20,21,21,
22,22,22,22,24,
24,24,27,27,27

3(b) Boxplot - Product A

Tukey quartiles (median-of-halves): min 16, Q1 19.5, median 21.5, Q3 24, max 27; no outliers.

Product A Sales - Boxplot

20 monthly observations; unit: hundreds of yuan



Tukey quartiles (median-of-halves); IQR = 4.5; no outliers.

3(e) Scatter Plot - Product A vs. Product B

Twenty paired monthly observations; point labels are month numbers; Pearson r = 0.831.

