HW1 答案检查与补图

基于你提供的 6 页作业逐题核对；计算结果已重新独立验证。

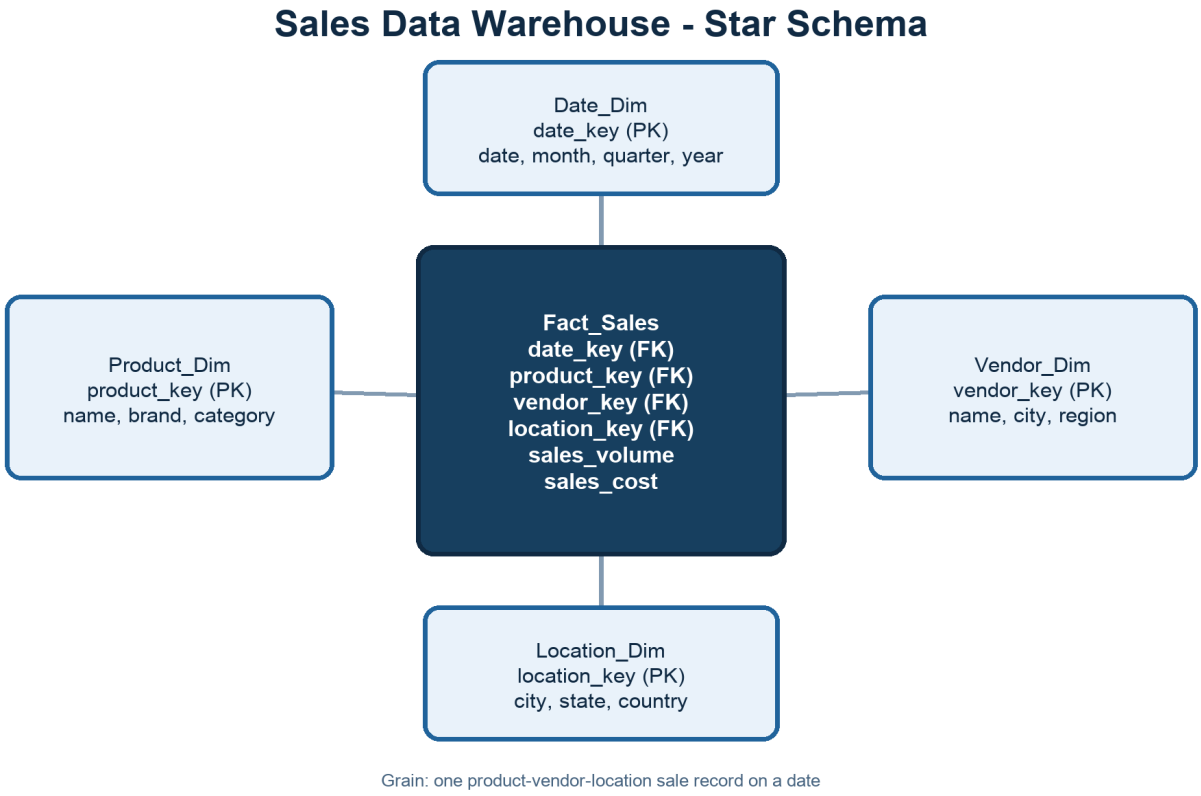
结论总览

题号	结论	需要处理的地方
1(a)	基本正确	图中 data_dim 应改为 date_dim；建议补出主键与常用属性。
1(b)	正确	按 year、vendor 分组并对 sales_volume 求和；题目中的 Los Angles 是拼写错误。
1(c)	基本正确	“ 稀疏所以易压缩 ” 不够严谨；是否易压缩主要取决于位串重复和压缩编码。
2	思路正确，层次需修正	粒度和表结构合理；probe_type -> manufacturer、climate_zone -> country 等并非严格概念层次。
3(a)	正确	均值 21.5，中位数 21.5，总体标准差 3.217，样本标准差 3.301。
3(b)	原答案缺失，已补	五数概括为 16, 19.5, 21.5, 24, 27；无离群值。
3(c)	正确	min-max 公式和 20 个结果均正确。
3(d)	正确	Pearson r = 0.8308627，属于较强正相关。
3(e)	原答案缺失，已补	散点图和线性趋势线见后文。
4(a)	正确	4 个等深箱及中位数平滑结果均正确。
4(b)	正确，但需注明约定	箱 3 中 23 到 22 和 24 距离相同；你的结果采用 “ 平局取较小边界 ” 。

整体判断：第 1、3、4 题的文字和计算答案质量较好；第 2 题建议按本报告中的修订版改写，以避免把普通属性误写成概念层次。

1(a) 修正版星型模式图

你原图的结构是星型模式，中心事实表也正确。唯一明确错误是顶端维表写成 data_dim，应该是 date_dim。下图同时补出了各维度的典型字段。



可直接使用的文字说明

事实表 Fact_Sales
的粒度应先说明，例如“某日期、某商品、某供应商、某地点的一条销售汇总记录”。四个外键分别连接 Date_Dim、Product_Dim、Vendor_Dim 和 Location_Dim；度量为 sales_volume 和 sales_cost。

1(b) 与 1(c) 的小修订

1(b) 的 OLAP 操作顺序可以写为：slice location = 'Los Angeles'；将 date 从日上卷到 year；将 product 上卷到 ALL；保留 vendor；最后按 year、vendor 分组并计算
SUM(sales_volume)。你的答案表达了这些要点，因此正确。

1(c) 建议把压缩部分改成：位图索引特别适合低基数维属性；AND、OR、NOT 可直接通过机器字位运算完成。使用游程长度等压缩技术时，具有长重复位段的位图压缩效果好。对于高基数列或频繁更新场景，位图数量、存储和维护成本可能很高。

2. 天气数据仓库：建议修订版

原答案选择星型模式是合理的，但需要先定义事实表粒度，并修正几个不成立的概念层次。推荐写法如下。

> 粒度：每个探针在每个地点、每个小时的一次观测。
>
> Weather_Fact(time_key, probe_key, location_key, air_pressure, temperature, precipitation, reading_count)

Time_Dim(time_key, timestamp, hour, day, day_of_week, month, quarter, year, season, season_year)
主层次：hour -> day -> month -> quarter -> year。season 可作为替代汇总路径，但最好与 season_year 搭配，避免跨年季节歧义。

Probe_Dim(probe_key, probe_id, probe_name, probe_type, manufacturer, model, install_date, status, station, network)
严格层次：probe -> station -> network。probe_type、manufacturer、model 是描述属性，不能一般性地写成 probe_type -> manufacturer。

Location_Dim(location_key, latitude, longitude, altitude_or_depth, land_ocean, city_or_area, region, country, climate_zone)
地理层次：site -> city_or_area -> region -> country。land_ocean 与 climate_zone 是独立分类属性；气候带可跨多个国家，因此不应写成 climate_zone -> country。

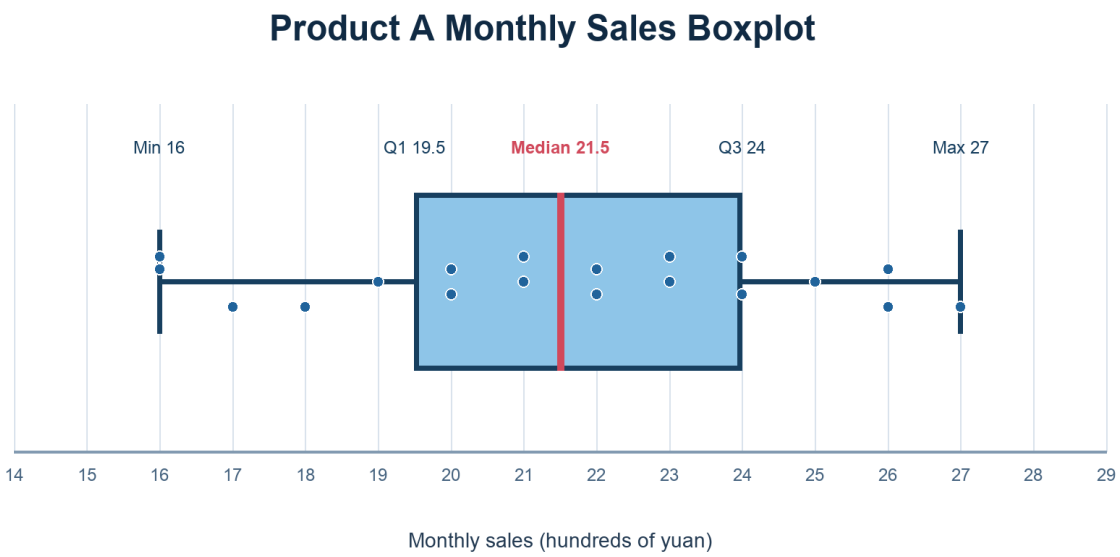
聚合规则：precipitation 在时间维上通常可求和；temperature 和 air_pressure 不应直接跨地点或时间求和，通常使用 AVG、MIN、MAX，并同时保留 reading_count 以支持正确的加权平均。

评分风险

若老师只检查是否有星型模式、事实表、维表和层次，你的原答案可获得大部分分数；若严格检查函数依赖和可汇总性，原层次中的 probe_type -> manufacturer、climate_zone -> country、land_ocean -> region 会被扣分。

3(b) 箱线图

按 Tukey 的上下半组中位数法：min = 16，Q1 = 19.5，median = 21.5，Q3 = 24，max = 27。IQR = 4.5，下界围栏为 12.75，上界围栏为 30.75，因此没有离群值。



说明：有些软件用线性插值得到 Q1 = 19.75；数据挖掘教材手算箱线图常采用 Tukey 法。无论哪种约定，都不会产生离群值。提交时建议明确写出所用四分位数规则。

3(a)、3(c)、3(d) 复核

3(a)：总和 430，n = 20，所以均值 21.5；排序后第 10、11 个数为 21、22，中位数 21.5；总体标准差约 3.22，样本标准差约 3.30，均正确。

3(c)：使用 x' = (x - 16) / 11，你列出的 20 个归一化值全部正确。

3(d)：Pearson 相关系数 r = 364.5 / sqrt(207 x 929.75) = 0.8308627，结论为较强正相关；你写的 r = 0.831 正确。

3(e) 商品 A 与商品 B 的散点图

横轴为商品 A，纵轴为商品 B；点旁数字 1-20 表示月份顺序。趋势线向上，和 r = 0.831 的正相关结论一致。



可直接写在图下：The scatter plot shows a clear upward trend. The Pearson correlation coefficient is r = 0.831, indicating a strong positive linear relationship between the monthly sales of products A and B.

4. Equal-depth binning 复核

排序数据为：16, 16, 17, 18, 19 | 20, 20, 20, 21, 21 | 22, 22, 23, 23, 24 | 24, 25, 26, 26, 27。每箱深度为 5，因此共 4 箱。

4(a) Bin median

四个箱的中位数分别为 17、20、23、26。你的平滑序列 17 x 5，20 x 5，23 x 5，26 x 5 完全正确。

4(b) Bin boundaries

箱 1 和箱 2 的结果正确；箱 4 的结果也正确。箱 3 的两个 23 到下边界 22 和上边界 24
的距离相同。你的结果把两个 23 都替换为
22，这在采用“ 平局取较小边界 ”的约定下正确。建议在答案中加一句说明。

> 采用平局取较小边界时，最终结果为：
> 16, 16, 16, 19, 19,
> 20, 20, 20, 21, 21,
> 22, 22, 22, 22, 24,
> 24, 24, 27, 27, 27。

最终建议

提交前至少完成三处修改：把第 1(a) 图中的 data_dim 改为 date_dim；用本报告的第 2
题层次替换原层次；插入第 3(b) 箱线图和第 3(e) 散点图。其余计算结果可保留。