Pump it Up：水泵状态预测

课程作业参考样例 | 真实公开数据实验 | 2026-10-16

本项目使用坦桑尼亚水点数据，将水泵状态分为正常、运行但需维修、无法运行三类。在 47,520 条开发样本内进行三折交叉验证，选中 catboost_depth8；其在 11,880 条保留验证样本上的 Accuracy 为 0.8109，Macro-F1 为 0.6819。随后使用全部 59,400 条带标签样本重训，生成 14,850 条测试预测。没有提交至比赛网站，线上分数未知。

数据部分	样本数	用途
带标签数据	59,400	原始 39 个预测字段及 id，目标另存于标签表
开发集	47,520	模型拟合；内部三折交叉验证选择候选配置
保留验证集	11,880	参数固定后的本地泛化评估
无标签测试集	14,850	全量重训后生成比赛格式预测

任务价值在于帮助识别需要检查和维修的水点。模型输出是历史记录条件下的状态分类，不是未来故障时间、维修成本或因果影响的估计。[1]

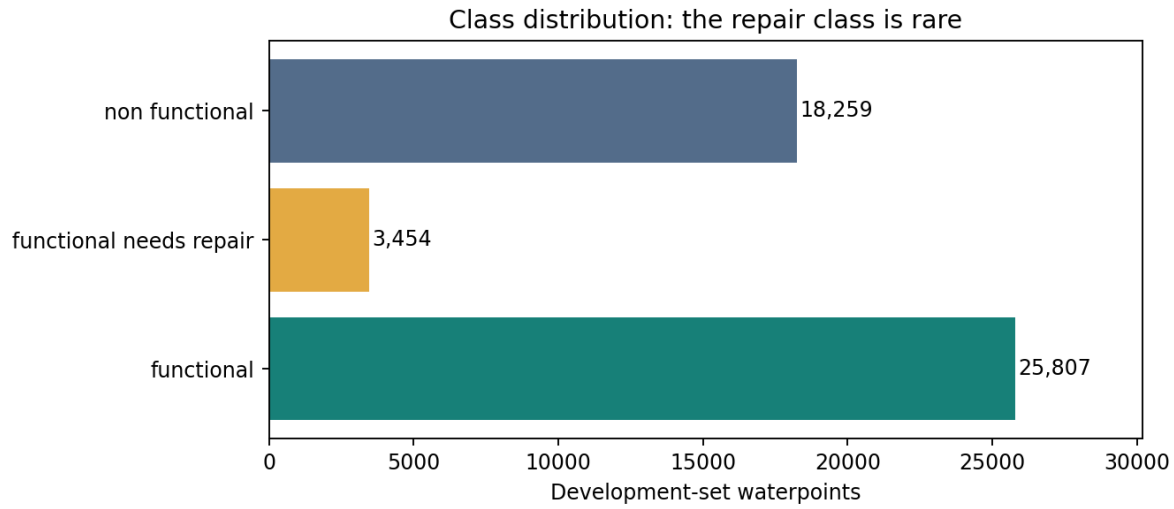


图 1 开发集类别分布；需维修类明显少于另外两类。

全部带标签数据中的类别计数：functional: 32,259；functional needs repair: 4,317；non functional: 22,824。

2 数据质量与特征处理

字段	开发集缺失率	处理方式
scheme_name	48.51%	删除高基数名称列
scheme_management	6.58%	保留并使用缺失标记
installer	6.14%	保留并使用缺失标记
funder	6.12%	保留并使用缺失标记
public_meeting	5.56%	保留并使用缺失标记

空值并不是唯一的数据质量问题。建造年份为 0、晚于记录年份的建造年份，以及接近 0 的经纬度，分别按无效年份和本数据中的无效坐标处理。海拔、人口和 amount_tsh 中的 0 没有被统一当成缺失。

数值特征增加泵龄、记录年/月、人口与 amount_tsh 的 log1p、部分零值标记；地区和区县代码按类别处理，并组合成地区内区县标识。类别文本只统一大小写和首尾空格，缺失值使用独立字符串。amount_tsh 按官方的静水头相关字段使用，不把它解释为水费。[1]

为控制复杂度，预先删除 id、记录者、水点名称、方案名称及部分重复层级列；工程后保留 35 个字段。该规则是教学设计，并没有通过本例证明为最优特征子集。

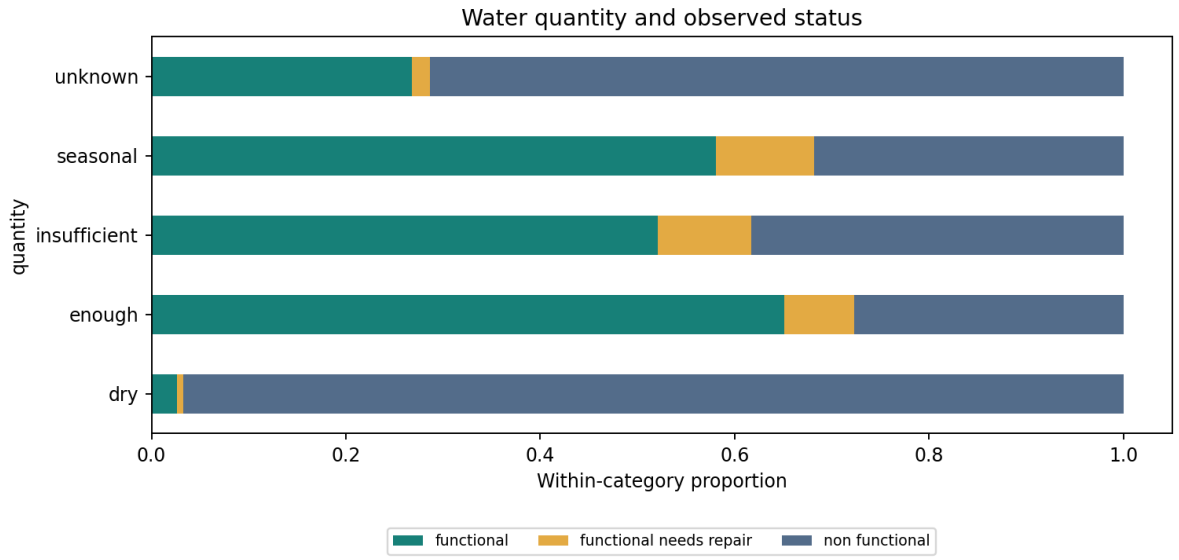


图 2 开发集内不同水量类别的状态比例；每行比例之和为 1。

图中关联不能单独证明因果关系，也不能直接推导实际维修优先级。

3 模型、选择标准与实验结果

多数类模型给出最低比较基准；逻辑回归提供线性基线；随机森林学习非线性交互；CatBoost 使用原生类别字段，避免为其预先做 One-Hot。[4] 所有比较使用同一个分层切分，随机种子均为 42。

固定配置：逻辑回归 C=1、lbfgs、最多 1500 次迭代；随机森林 240 棵树、min_samples_leaf=2、max_features=sqrt；CatBoost 分别为深度 6/650 轮和深度 8/850 轮，学习率均为 0.07。CatBoost 不使用保留验证集进行早停。

逻辑回归和随机森林使用折内中位数填补与缺失指示、数值标准化，以及 One-Hot 类别编码；One-Hot 的低频阈值为 10，每列最多 200 个输出类别。CatBoost 接收数值缺失和字符串类别。所有可学习处理均在训练折拟合，符合 Pipeline 防止泄漏的做法。[3]

模型	CV Accuracy	CV 标准差	验证 Accuracy	验证 Macro-F1
catboost_depth8	0.8043	0.0030	0.8109	0.6819
catboost_depth6	0.8011	0.0017	0.8051	0.6737
random_forest	0.7988	0.0018	0.8047	0.6579
logistic	0.7630	0.0001	0.7699	0.6210
majority	0.5431	0.0000	0.5431	0.2346

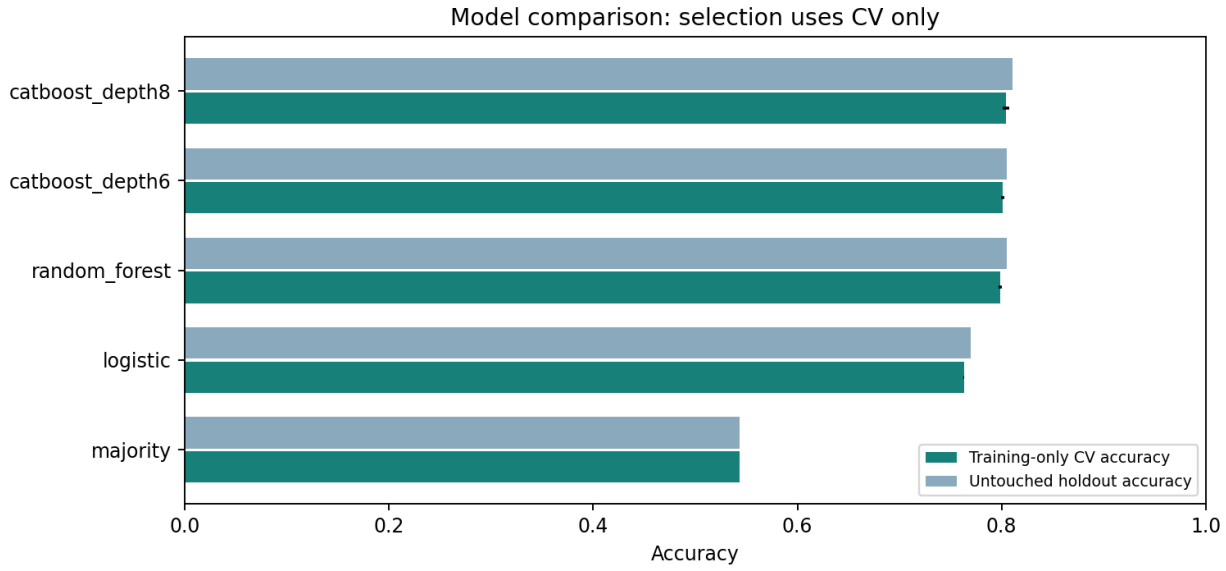


图 3 选择依据为开发集三折平均 Accuracy；误差棒为折间样本标准差，不是置信区间。

4 最终验证与错误分析

CV 选中的 catboost_depth8 在验证集上的 Accuracy 为 0.8109，比多数类基线高 26.78 个百分点。Macro-F1 为 0.6819。Accuracy=正确预测数/总样本数；Macro-F1 为三类 F1 的等权平均。两个指标应同时查看。

该配置在开发集上的拟合准确率为 0.8789，高于保留验证集约 6.80 个百分点。训练分数更高并不代表对新样本同样准确。

类别	Precision	Recall	F1	样本数
functional	0.7986	0.9095	0.8504	6,452
functional needs repair	0.6040	0.2827	0.3852	863
non functional	0.8530	0.7713	0.8101	4,565

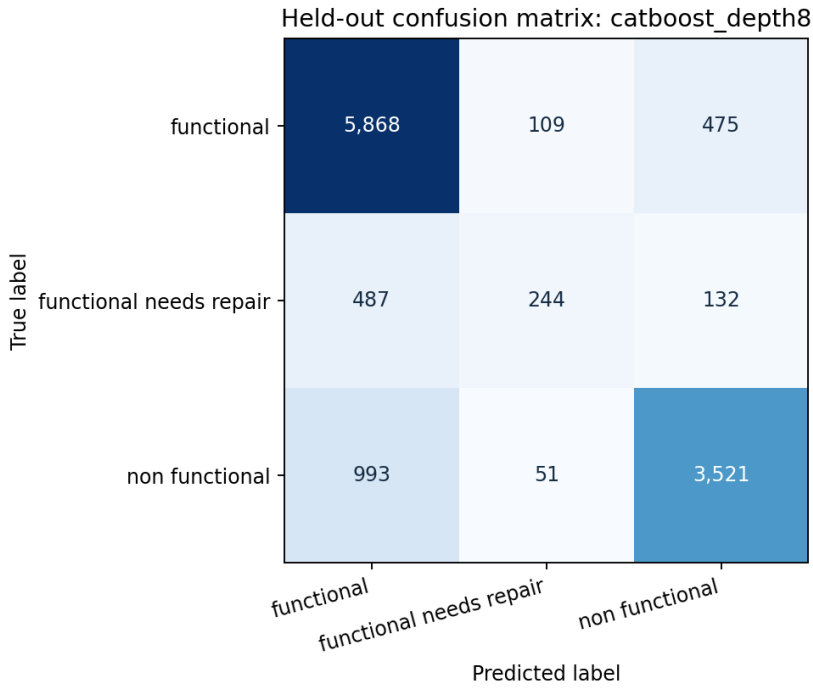


图 4 验证集混淆矩阵：行是真实状态，列是预测状态，数字是样本数。

需维修类的 Recall=0.2827，即真实需维修的水点中约 28.3% 被识别为该类。少数类仍有漏检风险。逐行错误样本保存在 results/errors.csv，可按地区、水量和水泵类型进一步检查误差分布。

5 模型解释、局限与改进

开发阶段模型的重要性靠前字段为：ward、quantity、extraction_type、funder、lga。下图为 CatBoost 的 PredictionValuesChange 重要性，用于解释模型依赖哪些字段；相关或重复特征会分摊重要性，因此不应把该排序解释为因果效应或业务收益。

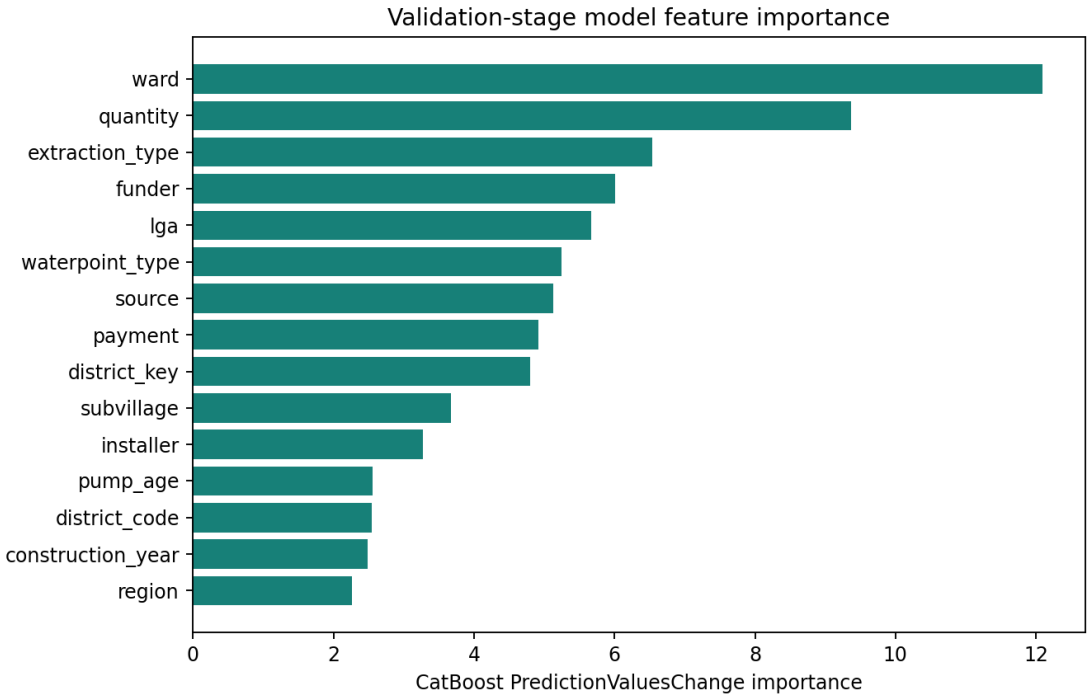


图 5 开发集拟合模型的前 15 个特征重要性。

地理泛化：随机分层切分保留类别比例，但邻近地区可能同时出现在开发集和验证集。若目标是部署到从未出现的地区，应另做按 region 或地理网格分组验证。本次未执行该实验。

类别权衡：需维修类样本少，可在训练内部比较类别权重、阈值或重采样策略；这些策略可能改善少数类召回，也可能降低总 Accuracy，必须先明确评价目标。

实验预算：这里只比较五组预先设定配置，各算法没有经过等预算的充分调参；当前结果只支持这几组配置的比较。未来可增加折数、训练内部搜索或保留新的最终测试集。

时效与解释：这些历史横截面特征只能支持相近采样条件下的状态分类。本地结果不代表线上分数，不能证明跨年份表现，也不能替代实地检查。

6 复现、交付文件与参考来源

本实验在实验室服务器的独立项目虚拟环境内运行。以下命令在项目根目录执行。训练仅用 CPU，模型线程数最多为 4；依赖版本、切分 ID、逐折分数和原始文件校验信息都已保存。

```
.venv/bin/python download_data.py
OPENBLAS_NUM_THREADS=4 OMP_NUM_THREADS=4 \
  .venv/bin/python pump_model.py --threads 4
.venv/bin/python execute_notebook.py
.venv/bin/python verify_outputs.py
```

文件	用途
Pump_it_Up_课程样例.ipynb	已执行，含中文讲解、数据分析、图表与结果
pump_model.py / requirements.txt	模型代码和固定的顶层依赖版本
data/raw/manifest.json	DrivenData 原始公开链接、文件大小及 SHA-256
results/model_comparison.csv / cv_folds.csv	模型比较与每一折的实际分数
results/validation_predictions.csv / errors.csv	逐条验证预测与错误样本
results/submission.csv	全量重训后的 14,850 条测试预测
results/audit.json / run_metadata.json	核对结果与执行环境记录

提交说明：模板来自 DrivenData 官方代码仓库，其全部 14,850 个 ID 和顺序已与原始测试集核对。[6] 脚本按模板 ID 对齐预测。未登录比赛账号、未上传预测。final_model.cbm 为全量模型，重新使用时需要先调用配套 PumpFeatures 转换原始特征。

复核通过：原始文件哈希、打乱标签后的 id 对齐、验证切分、逐行指标重算、混淆矩阵总量、交叉验证选择规则、模板打乱排序，以及保存模型对全部测试预测的复现。

[1] DrivenData：任务、原始字段和提交格式

[2] DrivenData：数据可用于课程项目的官方说明

[3] scikit-learn：Data leakage 与 Pipeline

[4] CatBoost：Categorical features

[5] Bull, Slavitt, Lipstein (2016): Harnessing the Power of the Crowd to Increase Capacity for Data Science in the Social Sector

[6] DrivenData 官方仓库：submission_format.csv